



باز

تشخیص تومور مغزی از تصاویر و مقایسه آن با روش های یادگیری انتقالی و شبکه عصبی کانولوشن سه لایه

محمدظفر خلیکی^۱ و محمد سینان باشارسلان^{۲*}

سلامت برای زندگی انسان بسیار مهم است. به طور خاص، سلامت مغز، که مجری این منبع حیاتی است، بسیار مهم است. تشخیص سلامت انسان توسط دستگاه های تصویربرداری تشدید مغناطیسی (MRI) آرایه می شود که به تصمیم گیرندگان سلامت در اندام های حیاتی مانند سلامت مغز کمک می کند. تصاویر این دستگاه هامنبعی از داده های بزرگ برای هوش مصنوعی هستند. این داده های بزرگ، عملکرد بالایی را در مسائلی طبقه بندی پردازش تصویر، که زیرمجموعه ای از هوش مصنوعی است، فراهم می کند. در این مطالعه، هدف ما طبقه بندی تومورهای مغزی مانند گلیوما، مننژیوما و تومور هیپوفیز از تصاویر MR مغز است. از شبکه های عصبی کانولوشن (CNN) و روش های VGG19، EfficientNetB4، inception-V3 و یادگیری انتقالی مبتنی بر CNN برای طبقه بندی استفاده شد. از امتیاز F، یادآوری، نقش پذیری و دقت برای ارزیابی این مدل ها استفاده شد. بهترین نتیجه دقت با VGG16 با ۹۸٪ به دست آمد، در حالی که مقدار امتیاز F برای همان مدل یادگیری انتقالی ۹۷٪، مقدار مساحت زیر منحنی (AUC) ۹۹٪، مقدار فراخوانی ۹۸٪ و مقدار دقت ۹۸٪ بود. معماری CNN و مدل های یادگیری انتقالی مبتنی بر CNN برای سلامت انسان در تشخیص زودهنگام و درمان سریع چنین بیماری هایی بسیار مهم هستند.

صنعت مراقبت های بهداشتی در سال های اخیر به سرعت با پیشرفت های فناوری متحول شده است و یکی از اجزای مهم این تحول، فناوری هوش مصنوعی (AI) است. هوش مصنوعی یک سیستم کامپیوتری است که هوش انسان مانند را شبیه سازی می کند و کاربردهای زیادی در پزشکی دارد. یکی از این حوزه ها، مبارزه با تومورهای مغزی است. تومورهای مغزی یک مشکل عمده سلامت عمومی در بخش مراقبت های بهداشتی هستند و تشخیص دقیق، درمان و فرایندهای پیگیری بسیار مهم هستند. هوش مصنوعی به ابزاری مهم برای بهبود این فرایندها تبدیل شده است و پتانسیل بالایی برای تشخیص و درمان زودهنگام تومورهای مغزی دارد.

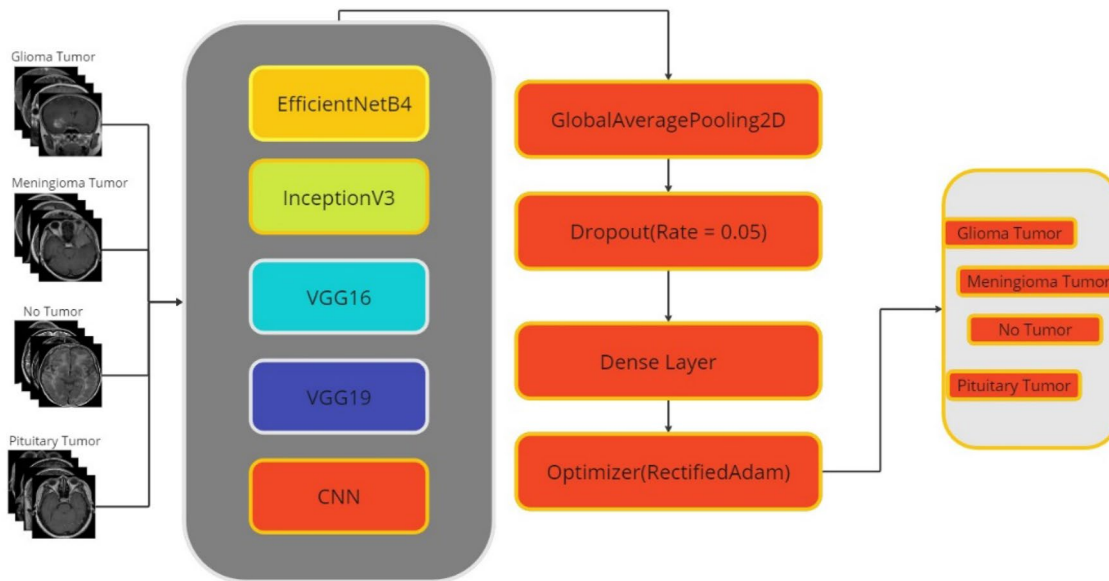
تومورهای مغزی به دلیل محل قرارگیری شان بر سلامت انسان تأثیر می گذارند. هوش مصنوعی برای کمک به تشخیص و درمان بیماری های پیچیده ای مانند تومورهای مغزی با ترکیب فناوری هایی مانند تجزیه و تحلیل کلان داده، یادگیری ماشین و یادگیری عمیق طراحی شده است. هوش مصنوعی با تجزیه و تحلیل تکنیک های تصویربرداری مغز، مانند تصویربرداری تشدید مغناطیسی (MRI)، توانایی تشخیص و طبقه بندی تومورها را دارد. الگوریتم های هوش مصنوعی می توانند به تعیین اندازه، محل، کلاس و میزان تهاجمی بودن تومورها کمک کنند. این امر به پزشکان کمک می کند تا تشخیص و برنامه درمانی دقیق تری داشته باشند و به بیماران کمک می کند تا سلامت خود را بهتر درک کنند.

هوش مصنوعی همچنین می تواند برای پیگیری پیشرفت بیمار در طول درمان مورد استفاده قرار گیرد. تجزیه و تحلیل های مبتنی بر هوش مصنوعی می توانند برای ارزیابی پاسخ به درمان و پیش بینی عود احتمالی تومور مورد استفاده قرار گیرند. به این ترتیب، برنامه های درمانی بیماران می توانند به طور مؤثرتری سازماندهی شوند و رویکردهای درمانی فردی توسعه یابند. در این مطالعه، تشخیص تفاوت روی تصاویر مغز انجام شد. طبقه بندی با روش های یادگیری انتقالی چندلایه CNN و مبتنی بر CNN روی ۴ کلاس برچسب گذاری شده توسط پزشکان انجام شد. سهم مطالعه به شرح زیر است.

- ما روش یادگیری انتقالی را با بالاترین عملکرد در فرآیند طبقه بندی روش های یادگیری انتقالی روی تصاویر مغز بررسی می کنیم.
- ما عملکرد CNN و یادگیری انتقالی را روی تصاویر مغز با استفاده از CNN به عنوان یک شبکه چند لایه و بدون استفاده از یادگیری انتقالی بررسی می کنیم.
- ما بررسی می کنیم که آیا می توان با یک مجموعه داده ی کج و بی کیفیت به نتایج خوبی دست یافت یا خیر.

نمودار جریان مطالعه در شکل نشان داده شده است.^۱

^۱آناشهریل بیل دبیرستان آنا تولی، ۳۴۷۲۰ استانبول، ترکیه. دانشکده مهندسی کامپیوتر، دانشکده مهندسی و علوم طبیعی، دانشگاه مدنیست استانبول، ۳۴۸۸۵ استانبول، ترکیه. *ایمیل: muhammet.basarslan@medeniyet.edu.tr



شکل ۱. نمودار جریان کار.

مطالعات انجام شده در مورد تومورهای مغزی در 5 سال گذشته از نمایه هایی مانند WOS و IEEE اسکن شده و جزئیات مطالعات مرتبط در این بخش توضیح داده خواهد شد.

در مطالعه ای روی 3064 تصویر MRI از 233 بیمار متعلق به 4 کلاس تومور مختلف (مننژیوم، گلیوما، هیپوفیز، تومور) با استفاده از ماشین بردار پشتیبان (SVM) روی مجموعه داده های تولید شده پس از پیش پردازش های مختلف، مقدار دقتی بین 94٪ به دست آمد. اسانتوش و همکارانش یک مدل طبقه بندی ارائه دادند که هدف آن تمایز بین بافت طبیعی و غیرطبیعی مغز بود. این سیستم بر ترکیبی از تکنیک های آستانه گذاری و تقسیم بندی حوزه آبخیز متکی بود. با استفاده از SVM، دقت طبقه بندی در تمام دسته ها به رقم چشمگیر ۸۵.۳۲٪ رسید. رافائل و همکارانش با استفاده از SVM برای طبقه بندی تومور مغزی به نرخ دقت ۸۹.۶٪ دست یافتند. به طور مشابه، گوپتا و ساسیدار با استفاده از SVM به دقت ۸۷٪ دست یافتند. گومای و همکارانش یک چارچوب طبقه بندی ارائه دادند که از قدرت ماشین یادگیری افرای منظم (RELM) برای تمایز بین تومورهای خوش خیم و بدخیم مغز استفاده می کند. مطالعه آنها شامل جمع آوری و پیش پردازش داده های MRI مربوط به مننژیوم، گلیوما و تومورهای هیپوفیز بود. فرآیند انتخاب ویژگی با استفاده از روش های GIST، GIST نرمال شده (NGIST) و PCA-NGIST انجام شد. با استفاده از یک روش اعتبارسنجی متقاطع پنج گانه دقیق، تکنیک RELM دقت کلی چشمگیر ۹۲.۶۱٪ را به دست آورد. با استفاده از یادگیری ماشین SVM روی مجموعه داده ای شامل ۹۰ تصویر مغز طبیعی و ۱۵۴ تصویر مغز تومور، دقت ۹۲٪ حاصل شد. ۳۲۶۴ تصویر تومور مغزی از Kaggle با استفاده از CNN، LSTM و ترکیبی CNN-LSTM طبقه بندی شدند. نتایج به دست آمده: ۹۲٪ CNN-LSTM، ۹۰.۲٪ LSTM، ۸۹٪ CNN دقت. ۷.

سربینواس و همکارانش یک مطالعه جامع شامل تجزیه و تحلیل مقایسه ای عملکرد مدل های CNN مبتنی بر یادگیری انتقالی که با معماری های VGG16، InceptionV3 و ResNet-50 از قبل آموزش دیده بودند، برای پیش بینی سلول های تومور مغزی انجام دادند. به طور خاص، InceptionV3 دارای دقت ۷۸٪، VGG16 دارای دقت بالای ۹۶٪ و ResNet-50 دارای دقت ۹۵٪ بود. در یک مطالعه مبتنی بر CNN از تصاویر تومور مغزی، چودوری، ماهانتی، کومار و میشر به دقت ۹۶.۰۸٪ دست یافتند. در حالی که مطالعه مارتینی و اورمن که مبتنی بر CNN بود، به دقت ۹۳.۹٪ دست یافت. آیین سال های ۲۰۰۵ تا ۲۰۱۰، مطالعه ای برای پیش بینی کلاس های مننژیوم، گلیوما و غده هیپوفیز از تصاویر مغز ۲۳۳ بیمار در چین انجام شد. در این مطالعه، از CNN چهار لایه استفاده شد. دقت ۹۱.۳٪ بود. در مطالعه ای که روی ۲۰۰ تصویر تومور مغزی انجام شد، دقت قطعه بندی تصویر ۹۲.۱۴٪ بود. مطالعات طبقه بندی روی ۱۰۲ بیمار تومور مغزی با استفاده از روش های یادگیری ماشین SVM و KNN به ترتیب به دقت ۸۵٪ و ۸۸٪ دست یافتند. در یک مطالعه طبقه بندی روی ۲۳۳ بیمار تومور مغزی، از SVM و KNN استفاده شد. در این مطالعه، نتیجه دقت ۹۱.۲۸٪ بود. در یک مطالعه طبقه بندی با استفاده از CNN روی ۲۳۳ تصویر بیمار مبتلا به مننژیوم، گلیوما یا تومور هیپوفیز، دقت با اعتبارسنجی متقابل پنج گانه ۹۱.۴۳٪ بود. نویسنده رویکرد جدیدی به نام شبکه کپسولی (CapsNet) را معرفی کرد که به طور مؤثر تصاویر MRI مغز و مرزهای تقریبی تومور را برای طبقه بندی تومورهای مغزی ادغام می کند. این مطالعه به دقت چشمگیر ۹۰.۸۹٪ در طبقه بندی دقیق تومورهای مغزی دست یافت. در این مطالعه، همانطور که در مقالات دیده می شود، از CNN و روش های یادگیری انتقالی مبتنی بر CNN برای تشخیص تومور مغزی استفاده خواهد شد.

روش مواد

این بخش، مجموعه داده ها، الگوریتم طبقه بندی (CNN) مورد استفاده در مطالعه و معماری های یادگیری انتقالی InceptionV3، VGG16 و VGG19، EfficientNetB4 که بر اساس این الگوریتم توسعه یافته اند را شرح می دهد.

منبع داده

مجموعه داده ها شامل مجموعه ۲۸۷۰ تصویر MRI مغز انسان است که به طور سیستماتیک در چهار دسته مختلف طبقه بندی شده اند: گلیوما، مننژیوم، بدون تومور و هیپوفیز. توزیع تصاویر برچسب گذاری شده در این چهار دسته در جدول نشان داده شده است. ابرای مرجع.

داده ها	گلیوما	مننژیوم	بدون تومور	هیپوفیز	مجموع
داده های آموزشی	۷۶۹	704	۳۱۶	۴۷۶	۲۴۵۲
داده های آزمایش	۹۲	۹۳	۴۹	۹۰	۳۲۴
داده های اعتبارسنجی	۱۳۸	۱۴۰	۷۵	۱۳۵	۴۸۸

جدول ۱. توزیع مجموعه داده های تومور مغزی پیش پردازش شده.

گلیوما شایع ترین نوع تومور مغزی بدخیم است و معمولاً در سلول های گلیال مغز و نخاع رخ می دهد. مننژیوم نوعی تومور مغزی خوش خیم است، اما بدون مداخله مناسب می تواند بدخیم شود. این کلاس ها توسط پزشکان برچسب گذاری شده اند. اندازه تصاویر ورودی 64×64 است. جدول ۱. امیازات مجموعه های آموزش، آزمایش و اعتبارسنجی را بر اساس کلاس نشان می دهد.

یادگیری عمیق

یادگیری عمیق زیرمجموعه ای از یادگیری ماشینی است که بر آموزش شبکه های عصبی مصنوعی برای انجام وظایف پیچیده با یادگیری الگوها و نمایش ها به طور مستقیم از داده ها تمرکز دارد. برخلاف رویکردهای سنتی یادگیری ماشینی که نیاز به مهندسی دستی ویژگی ها دارند، الگوریتم های یادگیری عمیق به طور خودکار ویژگی های سلسله مراتبی را از داده ها استخراج می کنند و منجر به ایجاد مدل های قدرتمند و بسیار دقیق می شوند.^{۲۸-۲۹} در این مطالعه، از معماری CNN استفاده شده است.

شبکه عصبی کانولوشن

شبکه های عصبی کانولوشن، پیشرفت بزرگی در یادگیری عمیق و بینایی کامپیوتر محسوب می شوند. این معماری ها به طور خاص برای استخراج ویژگی های معنادار از داده های بصری پیچیده، مانند تصاویر و ویدیوها طراحی شده اند. ساختار ذاتی CNN، متشکل از لایه های کانولوشن، لایه های ادغامی و لایه های کاملاً متصل، توانایی سیستم بینایی انسان را در تشخیص الگوها و ویژگی های سلسله مراتبی تقلید می کند. لایه های کانولوشن از عملیات کانولوشن برای تشخیص ویژگی های محلی استفاده می کنند که سپس با ادغام لایه هایی که اطلاعات را متراکم می کنند، به طور تدریجی خلاصه می شوند. سپس نمایش های سلسله مراتبی حاصل برای وظایف طبقه بندی یا رگرسیون به لایه های کاملاً متصل داده می شوند. CNN ها چشم انداز تشخیص تصویر را بازتعریف کرده اند و به موفقیت های چشمگیری در حوزه های مختلف از طبقه بندی تصویر و تشخیص اشیا گرفته تا تشخیص چهره و تجزیه و تحلیل تصاویر پزشکی دست یافته اند.^{۳۰}

انتقال یادگیری

یادگیری انتقالی به عنوان یک مفهوم اساسی در یادگیری ماشینی و یادگیری عمیق مطرح است که شامل استفاده از دانش به دست آمده از آموزش یک مدل برای یک کار خاص و متعاقباً اعمال آن دانش به یک کار مرتبط دیگر است. در حوزه شبکه های عصبی، یادگیری انتقالی قدرت قابل توجهی را نشان می دهد. این شامل فرآیند به کارگیری یک مدل از پیش آموزش دیده، که معمولاً روی یک مجموعه داده جامع و متنوع آموزش دیده است، و تنظیم دقیق آن روی یک مجموعه داده یاکار جدید است.^{۳۱-۳۳}

در این مطالعه، از مدل های یادگیری انتقالی VGG16، VGG19، InceptionV3 و EfficientNetB4 در فرآیند طبقه بندی استفاده شد.

وی جی سن

این معماری به عنوان یک مدل CNN قابل توجه معرفی شده توسط AlexNet^{۳۴} که بر اساس مدل قبلی خود، مدل AlexNet، ساخته شده است. این مدل با جایگزینی هسته های اولیه 11×11 و 5×5 در دو لایه کانولوشن اول با مجموعه ای از هسته های متوالی 3×3 ، به این بهبود دست می یابد. این مدل تقریباً 528 مگابایت فضای ذخیره سازی را اشغال می کند و با استفاده از داده های ImageNet، به دقت مستند 90.1٪ در بین 5 مدل برتر دست یافته است که تقریباً 138.4 میلیون پارامتر را در بر می گیرد. مجموعه داده های ImageNet شامل تقریباً 14 میلیون تصویر طبقه بندی شده در 1000 کلاس است. آموزش VGG16 بر روی GPU های قوی در طول چند هفته انجام شد. در این مطالعه از VGG16 و VGG19 استفاده شد.

کارآمدت نت

است. این سری مدل عمدتاً در وظایف پردازش بصری مانند طبقه بندی تصویر استفاده می شود "network" و "efficiency" ترکیبی از کلمات "EfficientNet" مقیاس پذیر و کارآمد است. هدف اصلی این مجموعه، دستیابی به عملکرد بهتر با پارامترهای کمتر است. اصطلاح CNN خانواده ای از مدل های EfficientNet داشت. ImageNet خانواده ای از مدل ها است که نتایج رقابتی را هم از نظر عملکرد و هم از نظر هزینه محاسباتی ارائه می دهد. این مدل، مدل هایی با اندازه و پیچیدگی متفاوت را در مقیاس های مختلف ارائه می دهد. مدل های با شماره بالاتر معمولاً بزرگتر و پیچیده تر هستند، اما به قدرت محاسباتی بیشتری نیاز دارند. این مدل، برترین عملکرد را در رقابت EfficientNet^{۳۴} داشت.

آغازیه کار

معماری Inception معماری ای است که در زمینه یادگیری عمیق و CNN استفاده می شود. این معماری برای انجام وظایف استخراج ویژگی و طبقه بندی با کارایی بیشتر طراحی شده است. معماری Inception که اولین بار در مقاله ای با عنوان "Going Deeper with Convolutions" معرفی شد، با هدف ارائه عملکرد بهتر هنگام پردازش مجموعه داده های بصری پیچیده طراحی شده است.^{۳۵} معماری Inception ساختاری دارد که شامل لایه های کانولوشن موازی است و خروجی های این لایه ها را با هم ترکیب می کند. به این ترتیب، می توان ویژگی هایی با اندازه های مختلف را به طور همزمان ثبت و پردازش کرد.^{۳۵}

معيار عملکرد

روش های ارزیابی عملکرد مانند دقت (Accuracy)، دقت (Precision)، فراخوانی (Recall) و امتیاز F برای ارزیابی مدل های ایجاد شده برای مسائل طبقه بندی مانند پردازش تصویر استفاده می شوند. این روش ها از ماتریس درهم ریختگی (Confusion Matrix) به دست می آیند. ماتریس درهم ریختگی در جدول (1) آورده شده است.^{۲۴}

در جدول ۲، نمادهان، پ، ن، و به ترتیب با مقادیر منفی واقعی، مثبت واقعی، مثبت کاذب و منفی کاذب مطابقت دارند. از معادلات (۱) به (۴)، دقت، دقت، فراخوانی و امتیاز F داده شده است به ترتیب.

$$(1) \quad \text{دقت} = \frac{\text{تی پ تی ن}}{\text{تی پ} + \text{فن} + \text{تی ن}}$$

$$(2) \quad \text{دقت} = \frac{\text{تی پ}}{\text{تی پوها}}$$

$$(3) \quad \text{نمای الکترودیک} = \frac{\text{تی پ}}{\text{پوز}}$$

$$(4) \quad \text{امتیاز} = \frac{2 * \text{دقت} * \text{به یاد بیاورید}}{\text{دقت} + \text{بازیابی}}$$

منحنی مشخصه عملکرد گیرنده (ROC)

منحنی ROC ابزاری گرافیکی است که برای ارزیابی عملکرد یک مدل طبقه بندی، به ویژه در سناریوهای طبقه بندی دودویی، استفاده می شود. این منحنی، تجسمی از حساسیت و ویژگی مدل را ارائه می دهد و تغییرات آنها را با تغییر آستانه ها نشان می دهد.^{۲۵} منحنی ROC با نرخ مثبت کاذب در محور X و نرخ مثبت واقعی (TPR) در محور Y رسم شده است. یک طبقه بندی کننده بهینه، که با TPR برابر با یک و نرخ مثبت کاذب برابر با صفر مشخص می شود، در گوشه بالا سمت چپ نمودار قرار دارد. منحنی در اطراف این نقطه شکل می گیرد و عملکرد مدل را در آستانه های مختلف نشان می دهد.^{۲۶}

علاوه بر این، مساحت زیر منحنی مشخصه عملکرد گیرنده (ROC)، که معمولاً به عنوان "مساحت زیر منحنی" شناخته می شود، به طور خلاصه عملکرد کلی مدل را در یک معیار واحد خلاصه می کند. مقدار AUC از 0 تا 1 متغیر است و مقادیر نزدیک تریبه 1 نشان دهنده افزایش توانایی تمایز مدل است.^{۲۷} منحنی ROC و مقدار AUC به عنوان ابزارهای ضروری برای مقایسه مدل ها و درک عملکرد مدل طبقه بندی عمل می کنند. مقدار AUC بالاتر عموماً نشان دهنده عملکرد برتر مدل است، در حالی که منحنی نقاط قوت و ضعف عملکرد مدل را در آستانه های مختلف نشان می دهد.^{۲۸}

تأیید مشارکت

از آنجایی که داده ها متن باز هستند، هیچ آزمایشی توسط نویسندگان روی انسان انجام نشده است. متن باز روی تصاویر MRI مطالعه شده است.

تنظیمات و نتایج آزمایش

این مطالعه به مسئله طبقه بندی تصویر با استفاده از روش های یادگیری عمیق می پردازد. مهم ترین و گسترده ترین مورد مطالعه در این زمینه، مسئله تصاویر سلامت است. در این زمینه، پنج مدل مختلف (VGG19، Multi-Layer CNN، InceptionV3، EfficientNetB4، VGG16) برای طبقه بندی تومورهای مغزی انتخاب شدند و عملکرد آنها در همان مجموعه داده ها مقایسه شد. 10٪ از مجموعه داده ها برای آزمایش، 15٪ برای اعتبارسنجی و 75٪ برای آموزش استفاده شد. تمام تنظیمات و نتایج آزمایش در Google Colab انجام شد.

چندلایه CNN

ابتدا باید معماری مدل خود را تعیین کنیم. فرم ورودی داده های ما ۴۰۰ × ۴۰۰ است و ۳ کانال دارد. از آنجایی که در مجموع ۴ کلاس مختلف داریم، تعداد کلاس های خروجی روی ۴ تنظیم شده است. مدل ما ساختاری دارد که شامل لایه های کانولوشن و pooling است. ابتدا، یک لایه کانولوشن ۳ × ۳ با ۳۲ فیلتر وجود دارد. پس از آن یک لایه pooling با حداکثر ۲ × ۲ قرار دارد. این کار با تأکید بر ویژگی های سطح پایین تر، اندازه را کاهش می دهد. برای عمیق تر کردن مدل، این ساختار دوبار تکرار می شود و لایه های کانولوشن با ۶۴ و ۱۲۸ فیلتر به ترتیب و لایه های pooling با حداکثر اندازه ۲ × ۲ اضافه می شوند.

ارزش واقعی			
مثبت	منفی	مجموع	
تخمین مقدار			
مثبت	ص	ص	تی پوها
منفی	ن	ن	تی ان گ
مجموع	پوز	منفی	م

جدول ۲. ماتریس درهم ریختگی.

نقشه‌ویژگی حاصل به یک بردار مسطح با یک لایه مسطح کننده تبدیل می‌شود. سپس یک لایه پنهان (متراکم) از ۱۲۸ نورون اضافه می‌شود. این لایه ویژگی‌های آموخته شده را عمیق تر کرده و تعمیم پذیری را افزایش می‌دهد. در نهایت، لایه خروجی ۴ نورون دارد و احتمالات بین کلاس‌ها را با تابع فعال سازی softmax محاسبه می‌کند. برای آموزش مدل خود، باید تابع و معیارهای بهینه را تعیین کنیم. در این مقاله، از الگوریتم بهینه سازی Rectified Adam استفاده می‌کنیم. این الگوریتم به صورت پویا نرخ یادگیری را تنظیم می‌کند و به استفاده کارآمدتر از گرادینت‌ها کمک می‌کند. همچنین، از آنتروپی متقاطع طبقه بندی شده به عنوان تابع زیان در طول آموزش استفاده می‌شود، زیرا به طور گسترده در کار طبقه بندی چندکلاسه استفاده می‌شود.

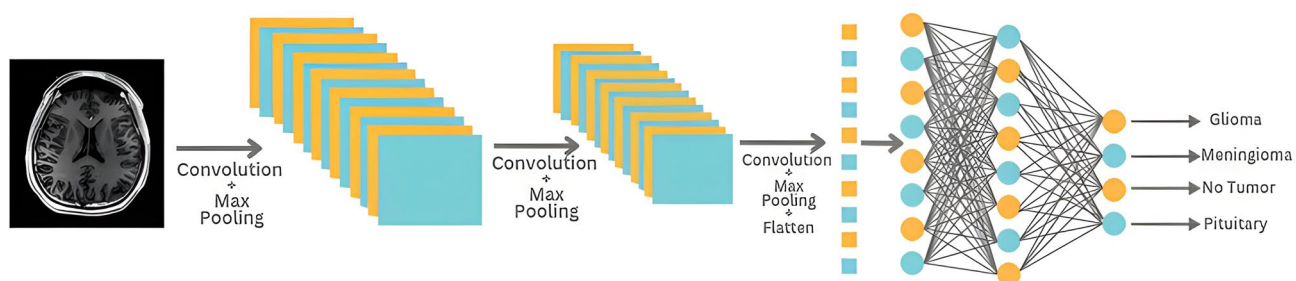
معیارهای ردیابی شده در طول آموزش، دقت، دقت و یادآوری هستند. این معیارها برای ارزیابی عملکرد طبقه بندی مدل مهم هستند. علاوه بر این، از یک یادآوری با نرخ یادگیری کاهش یافته (ReduceLROnPlateau) برای تنظیم پویای نرخ یادگیری استفاده می‌شود. این یادآوری، نرخ یادگیری را هنگامی که تابع زیان در طول فرآیند آموزش مسطح می‌شود، کاهش می‌دهد و در نتیجه آموزش پایدارتری حاصل می‌شود. دوره (epoch) روی ۱۴ و اندازه دسته روی ۱۰ تنظیم شده است.

یادگیری انتقالی مبتنی بر CNN

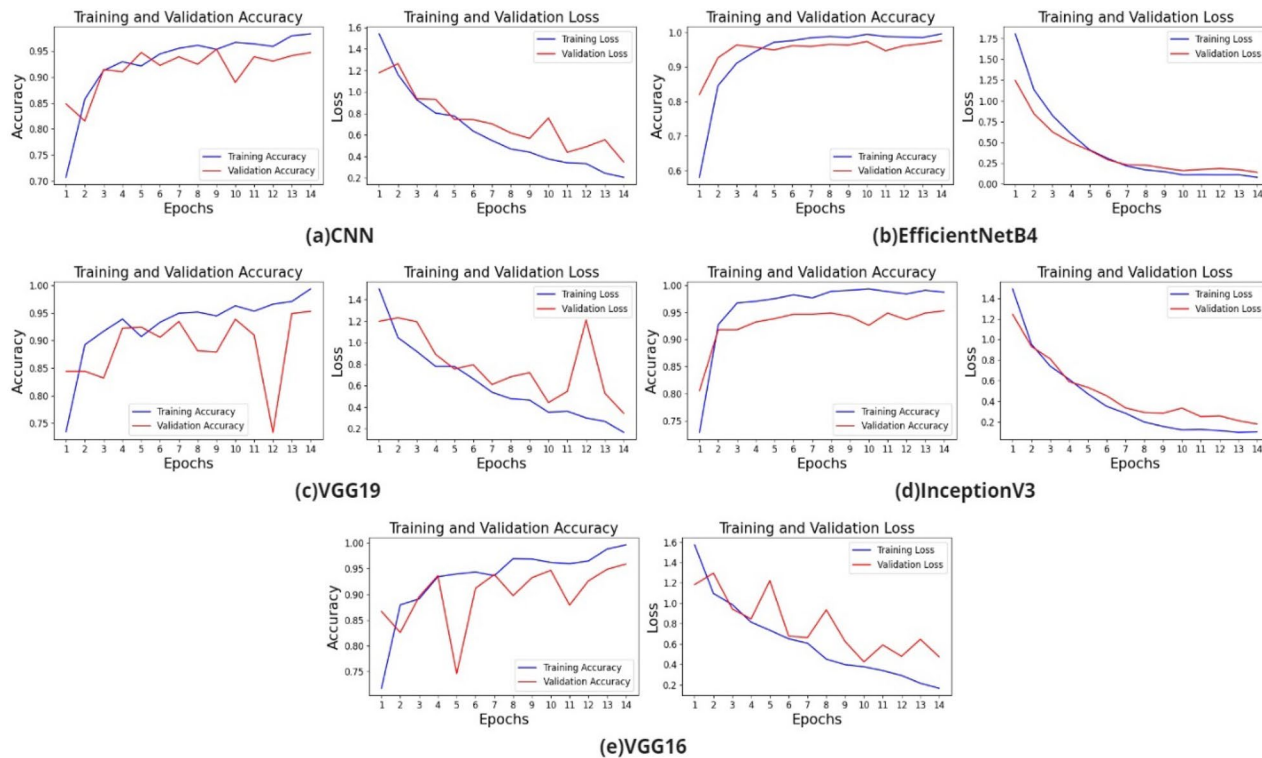
در معماری‌های یادگیری انتقالی، تمام پارامترها و لایه‌های خارج از مدل یکسان هستند، اما پس از حذف ۳ لایه آخر مدل‌های یادگیری انتقالی، لایه‌های منحصر به مجموعه داده‌ها به جای آنها اضافه می‌شوند؛ لایه GlobalAveragePooling2D شامل پارامترهای کمتری نسبت به لایه Flatten است که خطر بیش برآزش را کاهش می‌دهد و به ساخت یک مدل کارآمدتر کمک می‌کند. همچنین، در حالی که از لایه Flatten برای سازماندهی داده‌ها استفاده می‌شود، از لایه GlobalAveragePooling2D برای استخراج ویژگی استفاده می‌شود و فرآیند یادگیری شبکه را کارآمدتر می‌کند. با توجه به اینکه داده‌های آموزشی در مقایسه با داده‌های اعتبارسنجی تمایل به یادگیری بسیار سریعی دارند، نسبت لایه‌های حذف را در معماری‌های اصلی اصلاح کردیم. برای همه مدل‌ها، نرخ رقیق سازی روی 0.05 تنظیم شد. در طول فرآیند آموزش مدل، بهینه ساز تعیین شده "RectifiedAdam" بود که پارامترهای بهینه ساز به شرح زیر پیکربندی شدند: $\text{learning_rate} = 0.0001$, $\text{beta}_1 = 0.9$, $\text{beta}_2 = 0.999$ و $\text{epsilon} = 1e-08$. تابع زیان انتخاب شده $\text{categorical_crossentropy}$ است، در حالی که معیارهای مورد استفاده شامل دقت، یادآوری، دقت categorical و صحت هستند. این پیش آموزش مدل را تکمیل می‌کند. لایه نهایی مدل، لایه متراکم است که شامل 4 نورون است که معمولاً تعداد کلاس‌های خروجی در مسائل طبقه بندی است. تابع فعال سازی این لایه "softmax" است. تابع softmax مقادیر خروجی را به عنوان احتمالات بین کلاس‌ها قابل تفسیر می‌کند. علاوه بر این، نوع داده این لایه "float64" است، به این معنی که مقادیر خروجی از نوع دقت مضاعف 64 بیتی هستند. این لایه همچنین با استفاده از ویژگی "kernel_regularizer" منظم سازی را اعمال می‌کند. منظم سازی L2 که در اینجا استفاده می‌شود، با محدود کردن اندازه وزن‌ها، خطر بیش برآزش را کاهش می‌دهد. ضریب منظم سازی 0.1، که با "regularizers.l2:0.1" نشان داده می‌شود، اثربخشی منظم سازی را کنترل می‌کند. در طول فرآیند آموزش مدل، از تابع "ReduceLROnPlateau" از کتابخانه Keras به عنوان یک الگوریتم پس انتشار استفاده شد. این تابع به طور خودکار نرخ یادگیری را هنگامی که مدل به یک بهینه محلی نزدیک می‌شود یا زمانی که مقدار زیان کاهش نمی‌یافت، کاهش می‌دهد. پارامترهای تابع "ReduceLROnPlateau" به شرح زیر است: monitor: معیار نظارت شده معمولاً "val_loss" (زیان اعتبارسنجی) است. این معیاری است که برای تعیین اینکه آیا نرخ یادگیری باید کاهش یابد یا خیر، استفاده می‌شود:

- صبر: زمان انتظار برای کاهش نرخ یادگیری، یعنی مدت زمانی که معیار نباید بهبود یابد.
- عاملی که برای کاهش نرخ یادگیری استفاده می‌شود. برای مثال، مقدار 0.3 نرخ یادگیری را 30٪ کاهش می‌دهد: factor:
- حداقل نرخ یادگیری قابل دستیابی را مشخص می‌کند. این نرخ یادگیری را بدون اینکه بی نهایت کوچک شود، محدود می‌کند: min_lr:

استفاده از این ویژگی امکان آموزش مدل پایدارتر و کارآمدتر را فراهم می‌کند و فرآیند تنظیم دقیق پارامترهای آموزشی را بدون نیاز به تنظیم دستی نرخ یادگیری، ساده می‌کند. برنامه آموزشی طی ۱۴ دوره با دسته‌هایی با اندازه ۱۰ اجرا شد. جزئیات مدل CNN چندلایه مورد استفاده در این مطالعه در شکل ارائه شده است.^۲ که ویژگی‌های معماری آن را به طور خلاصه بیان می‌کند. نمودارهای تلفات دقت آموزش و اعتبارسنجی مدل‌های ایجاد شده با VGG19، EfficientNetB4، یادگیری انتقالی InceptionV3 و CNN در شکل 1 نشان داده شده است.^۳ میز ۳ نتایج دقت، امتیاز F، فراخوانی، دقت و AUC مدل‌های ایجاد شده در این مطالعه را نشان می‌دهد.



شکل ۲. معماری مدل CNN چند لایه.



شکل ۳. منحنی های یادگیری تلفات و دقت (الف) مدل CNN، (ب) مدل EfficientNetB4، (ج) مدل VGG19، (د) اینسپشن نسخه ۳، (ای) مدل VGG16.

مدل ها	دقت	نمره F	بهره یادکرد	دقت	AUC
VGG19	۹۶	۹۶	۹۶	۹۶	۹۹
کارآمد NETB4	۹۷	۹۶	۹۷	۹۷	۹۹
اینسپشن نسخه ۳	۹۶	۹۶	۹۶	۹۶	۹۹
مدل ۳ CNN	۹۱	۹۰	۹۱	۹۱	۹۸
VGG16	۹۸	۹۷	۹۸	۹۸	۹۹

جدول ۳. عملکرد (%) مدل های ایجاد شده در مطالعه.

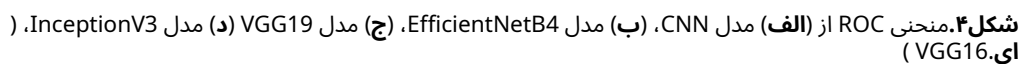
طبق جدول ۳ بهترین نتیجه دقت با VGG16 با ۹۷٪ بدست آمد. این روش با مقدار F-score ۹۷٪، مقدار AUC ۹۹٪، مقدار Recall ۹۸٪ و مقادیر دقت ۹۸٪ از سایر روش ها جلوتر است. منحنی های ROC مدل های ایجاد شده در این مطالعه در شکل نشان داده شده است. ۴.

باتوجه به مقادیر AUC در شکل ۴... مدل های یادگیری انتقالی VGG، InceptionV3 و EfficientNetB4 و مدل های ساخته شده با CNN ویژگی های متمایزی دارند. ماتریس درهم ریختگی مطالعه روی طبقه بندی گلیوما، مننژیوم، بیماران عادی غیر توموری، بیماران تومور هیپوفیز در مجموعه داده ها بر اساس نوع تومور در شکل نشان داده شده است. ۵.

همانطور که در ماتریس درهم ریختگی در شکل نشان داده شده است. ۵، عملکرد طبقه بندی برای هر چهار مدل (مدل های VGG16 و VGG19، مدل CNN، مدل EfficientNetB4، مدل InceptionV3) بالا است.

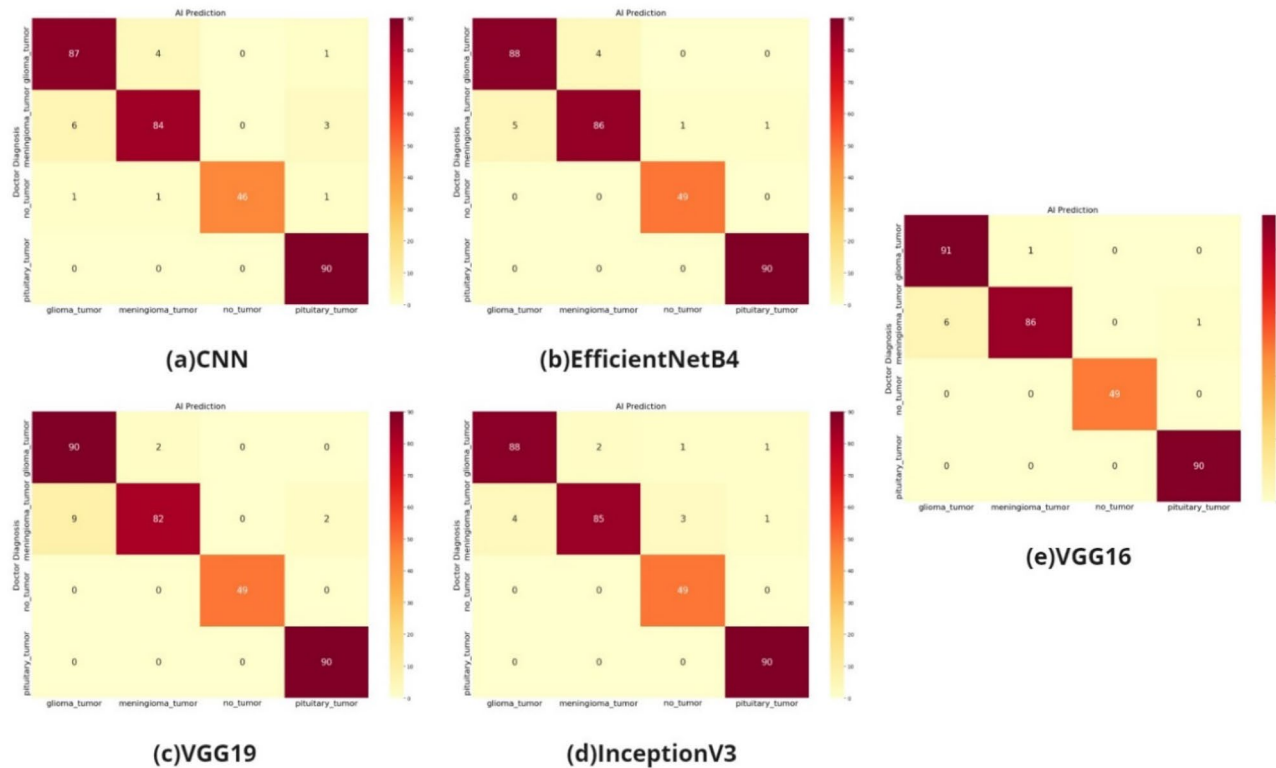
نتایج و بحث

به عنوان بخشی از این مطالعه، CNN و مدل های یادگیری انتقالی مبتنی بر CNN مانند VGG19، EfficientNetB4، InceptionV3 روی بیماران تومور مغزی مشترک متن باز آموزش داده شدند. بهترین نتیجه دقت با EfficientNetB4 با ۹۵٪ به دست آمد. مقایسه مطالعات تومور مغزی با مقالات در جدول نشان داده شده است. ۴. همانطور که در جدول نشان داده شده است. ۴، مدل های یادگیری انتقالی مبتنی بر CNN که در این مطالعه استفاده شدند، عملکرد بهتری داشتند. هوش مصنوعی در مراقبت های بهداشتی نقش مهمی در مدیریت بیماری های پیچیده ای مانند تومورهای مغزی ایفا می کند. هوش مصنوعی امکان تشخیص و درمان سریع تر، دقیق تر و مؤثرتر را فراهم می کند. با این حال، فناوری هوش مصنوعی قرار نیست به طور کامل جایگزین پزشکان شود، بلکه قرار است از کار آنها پشتیبانی و آنها را ارتقا دهد. برای تحقق پتانسیل کامل هوش مصنوعی، در نظر گرفتن مسائلی مانند اخلاق، امنیت و حریم خصوصی مهم است. در آینده، راه حل های مبتنی بر هوش مصنوعی به مدیریت بهتر تومورهای مغزی و سایر مشکلات سلامتی و بهبود کیفیت زندگی کمک خواهند کرد.



براساس نتایج این مطالعه، روش های یادگیری انتقالی باید به ویژه در برنامه های کاربردی مبتنی بر پردازش تصویر برای پشتیبانی از تصمیم گیرندگان حوزه سلامت ترجیح داده شوند. داده های به دست آمده از MRI یا CT می توانند به عنوان یک سیستم هشدار اولیه برای کمک به تصمیم گیرندگان حوزه سلامت در تصمیم گیری های سریع و دقیق مورد استفاده قرار گیرند. بنابراین، علاوه بر تجزیه و تحلیل تجربی، برنامه های کاربردی مبتنی بر هوش مصنوعی باید در اسرع وقت نقش فعال تری ایفا کنند. برای این منظور، تشخیص بیماری ها از تصاویر فوری CT یا MR با سال های آینده بررسی خواهد شد.

باانگیزه ما برای بررسی چگونگی عملکرد آن در مدل های یادگیری انتقالی مبتنی بر CNN تکی و چندلایه، مجموعه داده ها را بدون عملیات چرخش و برش، که مهمترین محدودیت مطالعه ما است، طبقه بندی کردیم.



شکل ۵. معیارهای سردرگمی (الف) مدل CNN، (ب) مدل EfficientNetB4، (ج) مدل VGG19 (د) مدل InceptionV3، (ای) VGG16

نویسندگان	مجموعه داده ها	مدل ها	دقت (%)
والیس و بوات ^۱	مجموعه داده های تومور مغزی ^{۲۸}	ماشین بردار پشتیبان	۷۴
سیرو کاریاسان ^۲	مجموعه داده های تومور مغزی خودشان		۸۵.۳۲
اورتیز-رامون و همکاران ^۳	مجموعه داده های تومور مغزی خودشان		۸۹.۶
گوپتا و ساسیدار ^۴	پایگاه داده چالش MICCAI 2012 ^{۲۸}		۸۷
گومای و همکاران ^۵	مجموعه داده های تومور مغزی ^{۲۸}	رلم	۹۲.۶۱
شاه جدو همکاران ^۶	مجموعه داده های مغزی کاگل ^{۱۱}	ماشین بردار پشتیبان	۹۲
ونکوتو و همکاران ^۷	مجموعه داده های تومور مغزی ^{۱۱}	سی ان ان، LSTM، CNN-LSTM	نسب آن ۸۹ LSTM90.02 CNN-LSTM9۲
سیرینیاس و همکاران ^۸	مجموعه داده های تومور مغزی ^{۱۱}	اینسپشن نسخه ۳ VGG16 ResNET5095	اینسپشن نسخه ۳ ۷۸ VGG1696 ResNET5095
چودوری و همکاران ^۹	مجموعه داده های تومور مغزی خودشان	سی ان ان	۹۶.۰۸
مارتینی و اورمان ^{۱۰}	مجموعه داده های تومور مغزی خودشان	سی ان ان	۹۳.۰۹
سرکارو همکاران ^{۱۱}	مجموعه داده های تومور مغزی خودشان	سی ان ان	۹۱.۰۳
آرونکومارو همکاران ^{۱۲}	هیچکدام	ماشین بردار پشتیبان، KNN	۹۲.۱۴
زاجاراک و همکاران ^{۱۳}	مجموعه داده های تومور مغزی خودشان		۸۸
چنگ و همکاران ^{۱۴}	مجموعه داده های تومور مغزی خودشان		۹۱.۲۸
پاول و همکاران ^{۱۵}	مجموعه داده های تومور مغزی خودشان		۹۱.۴۳
افشارو همکاران ^{۱۶}	مجموعه داده های تومور مغزی ^{۲۸}	کپس نت	۹۰.۸۹
این مطالعه	مجموعه داده های تومور مغزی ^{۱۱}	EfficientNetB4	۹۷
		اینسپشن نسخه ۳	۹۵
		VGG19	۹۶
		VGG16	۹۸
		سی ان ان	۹۱

جدول ۴. مقایسه با مطالعات قبلی در مورد تومور مغزی. بهترین نتایج در این مطالعه به دست آمد.

در دسترس بودن داده ها

این مجموعه داده به صورت متن باز به اشتراک گذاشته شده است. لینک دسترسی: <https://doi.org/https://doi.org/10.34740/kaggle/dsv/1183165>.

دریافت: ۱۵ سپتامبر ۲۰۲۳؛ پذیرش: ۲۴ ژانویه ۲۰۲۴

Published online: 01 February 2024

منابع

۱. والیس، دی. و بوات، آئی. اثر هانس باهوش که در یک مجموعه داده MRI تومور مغزی پر کاربرد یافت شده است، پزشکی. تصویر تحلیلی، **۷۷**، ۱۰۳۳۶۸. <https://doi.org/10.1016/j.media.2022.102368> (۲۰۲۲).
۲. هاجولی سیر، اس کی و کاربایاسا، کی. الگوریتم قطعه بندی آستانه و قطعه بندی حوزه آبخیز برای تشخیص تومور مغزی با استفاده از ماشین بردار پشتیبان. مجله مهندسی فناوری، پژوهش های یورو، **۵** (۴)، ۵۱۹-۵۱۶. <https://doi.org/10.24018/ejeng.2020.5.4.1902> (۲۰۲۰).
۳. MRI. تمایز متاستازهای مغزی به دنبال رویکرد رادیومیک مبتنی بر تجزیه و تحلیل بافت Glioblastomas مبتنی بر تجزیه و تحلیل بافت S., Mollá-Olmos, E. & Moratal, D. *Glioblastomas*. Ortiz-Ramón, R., Ruiz-España, R. *Ortiz-Ramón, R., Ruiz-España, R.* <https://doi.org/10.1016/j.ejemp.2020.06.016> (۲۰۲۰).
۴. گوپتا، م. و ساسیدار، ک. تشخیص غیرتهاجمی تومور مغزی با استفاده از ویژگی های بافت فرکتالی و معیارهای شکل مبتنی بر تصویربرداری تشدید مغناطیسی. در سومین کنفرانس بین المللی فناوری های نوظهور در مهندسی کامپیوتر: یادگیری ماشین و اینترنت اشیا (ICETCE) 2020. <https://doi.org/10.1109/ICETCE48199.2020.9091756>. IEEE, 2020, 93-97.
۵. گومای، ا.، حسن، م.، حسن، م.، ز.، آلاوی، ا. و فورتینو، گ. یک روش استخراج ویژگی ترکیبی با ماشین یادگیری افراطی منظم برای طبقه بندی تومور مغزی. دسترسی IEEE، ۳۶۲۶۶-۳۶۲۷۳. <https://doi.org/10.1109/ACCESS.2019.2904145> (۲۰۱۹).
۶. شهجاد، م.، گامبیر، د. و گاندی، ر. استخراج ویژگی ها برای طبقه بندی تصاویر MRI تومور مغزی با استفاده از ماشین بردار پشتیبان. در یازدهمین کنفرانس بین المللی محاسبات ابری، علوم داده و مهندسی (Confluence) 2021. <https://doi.org/10.1109/Confluence51648.2021.9377111>. IEEE, 2021, 767-772.
۷. ونکدو، ر.، حمید، م. ا. و فاطیما، ح. شناسایی و طبقه بندی تومور مغزی با استفاده از یادگیری عمیق مبتنی بر روش CNN-LSTM کامپیوتر. برق. مهندسی، **۱۰۱**، ۷۹۶۰-۷۹۶۰. <https://doi.org/10.1016/j.compeleceng.2022.107960> (۲۰۲۲).
۸. سربینواس، سی. و همکاران رویکردهای یادگیری انتقال عمیق در تحلیل عملکرد طبقه بندی تومور مغزی با استفاده از تصاویر MRI مجله مهندسی بهداشت **۲۰۲۳**، **۱۷**، ۱-۱۷. <https://doi.org/10.1155/2022/3264367> (۲۰۲۲).
۹. چودوری، سی ال، ماهانتی، سی.، کومار، آر. و میشر، بی کی. تشخیص و طبقه بندی تومور مغزی با استفاده از شبکه عصبی کانولوشن و شبکه عصبی عمیق. در کنفرانس بین المللی علوم کامپیوتر، مهندسی و کاربردهای آن (ICCSEA) 2020. <https://doi.org/10.1109/ICCSEA49143.2020.9132874>. IEEE, 2020, 1-4.
۱۰. مارتینی، ام ال و اورمن، ای کی. شناسایی تومور مغزی حین عمل با یادگیری عمیق. نات. کشیش کلین. انکول. **۱۷** (۴)، 200-201. <https://doi.org/10.1038/s41571-020-0343-9> (۲۰۲۰).
۱۱. سارکار، س.، کومار، آ.، آج، س.، چاکرابورتی، س.، سیم، ج.، س.، و کیم، ه. س. یک رویکرد مبتنی بر CNN برای تشخیص تومور مغزی با استفاده از اسکن های MRI، پیش بینی شدت بیماری فیبروز ریوی ایدیوپاتیک (IPF) در بیماران مبتلا به بیماری ریه، پروژه مشاهده سیستم فیزیکی سایبری مبتنی بر IoT، پروژه مشاهده یک رویکرد مبتنی بر CNN برای تشخیص تومور مغزی با استفاده از اسکن های MRI. [آنلاین]. <https://doi.org/10.1109/ICETCE48199.2020.9091756>. <https://doi.org/10.1109/ICETCE48199.2020.9091756> (۲۰۲۰).
۱۲. آرونکومار، ن. و همکاران رویکرد قطعه بندی و طبقه بندی کاملاً خودکار مبتنی بر مدل برای تومور مغزی MRI با استفاده از شبکه های عصبی مصنوعی. کنکور کامپیوتر. **۳۳**، ۴۹۶۲. <https://doi.org/10.1002/cpe.4962> (۲۰۲۰).
۱۳. زاجاراک، ای. آی. و همکاران طبقه بندی نوع و درجه تومور مغزی با استفاده از بافت و شکل MRI در یک طرح یادگیری ماشین مگن. رزون. پزشکی **۶۲** (۶)، ۱۶۱۸-۱۶۱۸. <https://doi.org/10.1002/mrm.22147> (۲۰۰۹).
۱۴. چنگ، جی. و همکاران بهبود عملکرد طبقه بندی تومور مغزی از طریق افزایش و افراز ناحیه تومور پلاس وان (e0140381). <https://doi.org/10.1371/journal.pone.0140381> (۲۰۱۵).
۱۵. پاول، جی اس، پلاسارد، ای جی، لندمن، بی ای، و فابری، دی. یادگیری عمیق برای طبقه بندی تومور مغزی. در (کرول، ای. و گیمی، بی. ویراستاران)، **۲۰۱۷**. <https://doi.org/10.1117/12.2254195> (۲۰۱۷).
۱۶. افشار، پ.، پلاتانیوتیس، ک. ن.، و محمدی، ا. شبکه های کپسولی برای طبقه بندی تومور مغزی بر اساس تصاویر MRI و مرزهای تومور. **۲۰۱۸**. <https://doi.org/10.1109/ICETCE48199.2020.9091756> (۲۰۲۰).
- کاگل (2020). MRI (طبقه بندی تومور مغزی). <https://doi.org/10.34740/kaggle/dsv/1183165>. Sartaj, B., Ankita, K., Prajakta, B., Sameer, D., & Swati, K.
۱۸. باسارسلان، ام اس و کایالپ، اف. تحلیل احساسات با روش های یادگیری ماشین در رسانه های اجتماعی. توزیع کنید. محاسبه کنید. آرتیف. هوشمند جی. *Adv.* **39** (3)، 15-15. <https://doi.org/10.14201/ADCAJ202093515> (۲۰۲۰).
۱۹. لکان، وای.، بنگو، وای. و هینتون، جی. یادگیری عمیق طبیعت (۷۵۳). <https://doi.org/10.1038/nature14539> (۲۰۱۵).
۲۰. سوگ، ا.، اردوگموس، پ.، و یلین، ای. تشخیص فونت و حروف ترکی در تصاویر با یادگیری عمیق. درکنگره بین المللی کلان داده. یادگیری عمیق و مبارزه با تروریسم سایبری (IBIGDELFT) سال ۲۰۱۸. <https://doi.org/10.1109/IBIGDELFT.2018.8625333>. IEEE, 2018, 61-64.
۲۱. بال، ف. و کایالپ، ف. یک روش ترکیبی جدید مبتنی بر یادگیری عمیق برای تعیین بهره وری محصولات کشاورزی: مطالعه موردی سیب. دسترسی IEEE، **۱۱**، ۷۸۰۸-۷۸۱۱. <https://doi.org/10.1109/ACCESS.2023.3238570> (۲۰۲۳).
۲۲. کایاکوس، ای تی و اردوگموس، پی. مقایسه تجربی شبکه های عصبی عمیق از پیش آموزش دیده که به طور گسترده برای وظایف طبقه بندی تصویر استفاده می شوند، به منظور آشکار کردن نوید یادگیری انتقالی. کنکور کامپیوتر. **۷۲**، ۷۲۱۶. <https://doi.org/10.1002/cpe.7216> (۲۰۲۲).
۲۳. باشارسلان، ام اس و کایالپ، اف. MBI-GRUMCONV: یک مدل یادگیری عمیق جدید مبتنی بر Multi Bi-GRU و CNN برای تحلیل احساسات رسانه های اجتماعی. جی. راینش ابری. **۱۲** (1)، 3.5. <https://doi.org/10.1186/s13677-022-00386-3> (۲۰۲۳).
۲۴. سیمونیان، ک. و زیسمن، آ. شبکه های کانولوشنی بسیار عمیق برای تشخیص تصویر در مقیاس بزرگ، **۲۰۱۴**.
۲۵. چولت، اف. استئنا: یادگیری عمیق با کانولوشن های جداشدنی عمیق، **۲۰۱۶**.
۲۶. کایالپ، ف.، باسارسلان، ام. اس، و پولات، ک. TSCBAS: یک روش جدید انتخاب ویژگی مبتنی بر همبستگی و کاربرد آن در تحلیل ریزش مشتریان مخابراتی. درکنفرانس بین المللی هوش مصنوعی و پردازش داده ها (IDAP) 2018. <https://doi.org/10.1109/IDAP.2018.8620935>. IEEE, 2018, 1-5.
۲۷. گولمز، س.، کاکیشیم، آگ. و سوگوکینار، آی. تحلیل ویژگی های پویا در تشخیص باج افزار با استفاده از روش های مبتنی بر یادگیری عمیق. در یازدهمین سمپوزیوم بین المللی جرم شناسی دیجیتال و امنیت (ISDFS)، چاتانوکا، تنسی، ایالات متحده آمریکا، **۲۰۲۳**، ۶-۱. <https://doi.org/10.1109/ISDFS58141.2023.10131862> (۲۰۲۳).
۲۸. چنگ، جی. و همکاران بهبود عملکرد طبقه بندی تومور مغزی از طریق افزایش و افراز ناحیه تومور پلاس وان (e0140381). <https://doi.org/10.1371/journal.pone.0140381> (۲۰۱۵).

مشارکت های نویسنده

مفهوم سازی، تعریف روش شناسی، ارزیابی نتایج، و پیش نویس اصلی و بررسی، نظارت، نویسندگان تأیید می کنند که هیچ تصویری از هیچ شرکت کننده ای در مقاله وجود ندارد. MSB، تحلیل داده ها، آزمایش ها و ارزیابی ها، تهیه پیش نویس مقاله، MKZ.

منافع رقابتی

نویسندگان هیچ گونه تضاد منافعی را اعلام نمی کنند.

اطلاعات تکمیلی

مکاتبات و درخواست های مربوط به مطالب باید به موسسات خدمات مالی (MSB) ارسال شود.

اطلاعات مربوط به چاپ مجدد و مجوزها موجود است در www.nature.com/reprints.

یادداشت ناشر: اشپرینگر نیچر در مورد ادعاهای مربوط به صلاحیت قضایی در نقشه های منتشر شده و وابستگی های سازمانی بی طرف باقی می ماند.

دسترسی آزاد این مقاله تحت مجوز بین المللی Creative Commons Attribution 4.0 منتشر شده است که استفاده، اشتراک گذاری، اقتباس، توزیع و تکثیر در هر رسانه یا ... را مجاز می داند. قالب، تا زمانی که به نویسنده (گان) اصلی و منبع، اعتبار مناسب بدهید، پیوندی به مجوز Creative Commons ارائه دهید و در صورت ایجاد تغییرات، مشخص کنید. تصاویر یا سایر مطالب شخص ثالث در این مقاله در مجوز Creative Commons مقاله گنجانده شده اند، مگر اینکه در خط اعتباری مطلب، خلاف آن ذکر شده باشد. اگر مطلبی در مجوز Creative Commons مقاله گنجانده نشده باشد و استفاده مورد نظر شما طبق مقررات قانونی مجاز نباشد یا از استفاده مجاز فراتر رود، باید مستقیماً از دارنده حق چاپ اجازه بگیرید. برای مشاهده نسخه ای از این مجوز، به <http://creativecommons.org/licenses/by/4.0/>.

© نویسنده (گان) ۲۰۲۴